Laboratorio 1, comentado

Unidad 2 — Sesión 1 — Regresión, clasificación, y por qué un número solo no basta

Dr. Carlos Hernández Ulloa
Reiner Romero Garrido

Facultad de Ingeniería — Universidad San Sebastián

Qué es este documento

Junto con estas láminas se publica **el cuaderno resuelto y ejecutado**:

`Semana01_Lab1_Regresion_y_Clasificacion_SOLUCION_Ejecutado_en_COLAB.ipynb`

El cuaderno muestra **qué salió**. Estas láminas dicen **qué significa**, y agregan lo que el cuaderno no trae: **las cinco respuestas escritas**, que quedaron en blanco a propósito para que las contestaran ustedes.

> ***La entrega sigue siendo la de siempre:*** *el cuaderno con las cinco celdas de verificación en verde y las cinco respuestas escritas. Estas láminas son para comparar después de haberlo intentado, no antes.*

Todas las cifras están verificadas dos veces

Dónde se corrió	Para qué
Google Colab	es el entorno en que ustedes trabajaron: mismas versiones, mismo resultado
El computador del curso	para que ninguna cifra de este PDF dependa de una sesión de Colab ya cerrada

Las dos corridas dan **exactamente los mismos números**, hasta el tercer decimal. Es lo que garantiza la semilla fija de `generar_datos_coronel()`.

> *Si a alguno le salió distinto, no es el azar: es una celda ejecutada fuera de orden.*

Bloque 1 — La basura que `.head()` no muestra

```
--- valores faltantes ---     dias_en_patio    30
--- filas duplicadas: 12 ---
--- resumen numérico ---      peso_ton   mean 176.45   max 28400.00
```

Tres problemas, y **ninguno de los tres aparece mirando las primeras filas**:

Problema	Con qué se encuentra	Cuántas filas
Faltantes en `dias_en_patio`	`.isna().sum()`	30
Duplicados exactos	`.duplicated().sum()`	12
Pesos cargados en kilos	`.describe()`	6

De 612 filas quedaron **594**. Un contenedor de 28.400 toneladas no existe: son kilos en una columna que dice toneladas.

Respuesta 1 — ¿cuándo eliminar filas es mala idea?

Eliminar 18 de 612 fue barato: el 3%. Deja de serlo en tres situaciones:

Situación	Qué pasa si eliminas	Qué hacer en su lugar
Los faltantes son **muchos** (20% o más)	te quedas sin datos	imputar, y agregar una columna que marque «esto fue imputado»
Los faltantes **no son al azar**	sesgas el modelo	modelar la ausencia: a veces el faltante *es* la señal
El registro es **caro o irrepetible**	pierdes información única	imputar y documentarlo

> *El caso peligroso es el segundo. Si los contenedores sin* `dias_en_patio` *son justo los que entraron con el sistema caído en la madrugada, borrarlos elimina el turno de noche entero — y el modelo nunca sabrá que existe.*

Bloque 2 — Una variable, una recta

```
pendiente: 0.33987   intercepto: 8.905
```

El valor verdadero con el que se generaron los datos era **0.35**.

Con una sola variable, sin corregir nada y sin separar prueba, la estimación cae a **cuatro centésimas** del valor real. El `coef_` es la m y el `intercept_` es la n de $y = mx + n$: **eso es todo lo que el modelo aprendió**.

> *El error más frecuente del bloque fue `datos["col"]` en vez de `datos[["col"]]`. El corchete simple entrega una Serie; Scikit-learn pide una tabla de dos dimensiones, aunque tenga una sola columna.*

Respuesta 2 — ¿cuál de las dos explica mejor?

`dias_en_patio`, y por bastante más de lo que sugiere la pendiente.

Predictor	Pendiente	R^2 de esa sola variable
`distancia_muelle_m`	0.00237	**0.048**
`dias_en_patio`	0.33987	**0.357**

La pendiente **no sirve para comparar**: 0.0024 y 0.34 están en unidades distintas — horas por metro contra horas por día. Una variable que se mide en milímetros tendría una pendiente diminuta y podría explicarlo todo.

> *Lo que sí compara es el **R^2**, que no tiene unidades. Los días explican siete veces más que la distancia. Y se veía en el gráfico: la nube de la distancia es una mancha sin dirección.*

Bloque 3 — Los cuatro coeficientes, recuperados

Variable	Estimado	Verdadero
`peso_ton`	0.0800	0.10
`dias_en_patio`	0.3314	0.35
`distancia_muelle_m`	0.0020	0.0020
`altura_pila`	0.8297	0.80

Este es el bloque que justifica haber usado datos sintéticos. «Aprender los parámetros» deja de ser una frase: son cuatro números que estaban escritos en la celda de generación y que el ajuste volvió a encontrar, con 594 filas y ruido de por medio.

> *Es la única vez en el curso en que van a poder comprobarlo. Con datos reales, los coeficientes verdaderos no existen en ninguna parte.*

Respuesta 3 — ¿cambian mucho las métricas?

Partición	R^2	MAE
`random_state=42`	0.579	**1.706 h**
`random_state=0`	0.584	**1.925 h**

El R^2 se movió 0.9%. El MAE se movió 13%. Es el mismo modelo, los mismos datos y las mismas 594 filas: lo único que cambió fue qué 149 filas cayeron en la prueba.

Y las dos métricas no se movieron igual porque no miden lo mismo: el R^2 se compara contra la varianza **de su propio conjunto de prueba**, así que una prueba más difícil se castiga a sí misma. El MAE no: son horas, y si la partición trajo casos más duros, sube.

> ***Un número solo no es un resultado.*** *Un resultado es un número con una idea de cuánto se mueve.*

Bloque 4 — De «cuánto» a «cuál»

```
proporción que requiere inspección: 0.48
```

Modelo	Exactitud
Siempre la clase más frecuente *(el modelo tonto)*	**0.520**
Logística, partición 42	0.691
Logística, partición 0	0.745

La ventaja sobre no hacer nada es real, y es modesta. **Hay una razón concreta:** lo que más determina si un contenedor se inspecciona es `tipo_carga` — peligroso y refrigerado se inspeccionan mucho más — y esa columna es de texto, así que quedó fuera.

> *Es el mismo 42% ausente del Bloque 3, visto desde la clasificación.*

Respuesta 4 — ¿qué le harías al modelo para usar `tipo_carga`?

No hay que cambiar de modelo. Hay que cambiar la entrada.

Lo que no sirve	Por qué
Pasar la columna tal cual	Scikit-learn no acepta texto
Cambiar a un modelo «más potente»	ninguno lee texto sin codificar tampoco
`seco→0, granel→1, refrigerado→2, peligroso→3`	inventa un orden que no existe — el Lab 2 lo mide

La respuesta correcta es **una columna por nivel**: cuatro columnas de ceros y unos, y cuatro efectos independientes que el modelo estima por separado.

> *Eso es `pd.get_dummies`, y es el Laboratorio 2 completo. En el Bloque 5 de la clasificación pasa lo mismo: `tipo_carga` es justamente la variable que fabricó la etiqueta.*

Bloque 5 — Las dos matrices, casilla por casilla

Partición 42 — exactitud 0.691

```
[[53 25]
 [21 50]]
```

25 inspecciones innecesarias

21 contenedores que se fueron sin revisar

Partición 0 — exactitud 0.745

```
[[64 14]
 [24 47]]
```

14 inspecciones innecesarias

24 contenedores que se fueron sin revisar

La partición con mejor exactitud dejó pasar *más* contenedores peligrosos. 0.745 le gana a 0.691 y sin embargo los falsos negativos subieron de 21 a 24.

> *La exactitud suma los dos tipos de error en un solo número, como si costaran lo mismo. En un puerto no cuestan lo mismo.*

Respuesta 5 — si a tu compañero le dio distinto, ¿quién tiene razón?

Ninguno de los dos, y esa es la respuesta completa.

	Logística	Árbol	Gana
`random_state=42`	0.691	0.725	árbol
`random_state=0`	**0.745**	0.725	logística

Con 149 casos de prueba, el error estándar de una exactitud cercana a 0.73 es de **±3.6 puntos**. La diferencia entre los dos modelos es de **2 puntos**: cabe entera dentro del ruido de medir.

> *Cómo se resuelve: **validación cruzada** — partir cinco o diez veces, promediar, y mirar también la dispersión. Si los intervalos se solapan, la respuesta es «no se distinguen con estos datos», no elegir el que salió arriba.*

Laboratorio 1 — el saldo

Lo que quedó demostrado	Cifra
Los tres problemas de suciedad no se ven en `.head()`	30 · 12 · 6 filas
La regresión recupera los coeficientes que generaron los datos	0.080 / 0.331 / 0.0020 / 0.830
Cuatro columnas numéricas explican el 58%	R^2 0.579
Comparar contra el modelo tonto	0.520
Una sola partición no distingue dos modelos parecidos	±3.6 puntos

Y una deuda: cinco columnas de texto descartadas, y un 42% sin explicar.

La deuda que este laboratorio deja

Cuatro columnas numéricas explican el 58%. Falta el 42%.

Y no está escondido: son las **cinco columnas de texto** que descartamos en el Bloque 3 porque Scikit-learn no las acepta tal cual.

Columna	Qué es	Niveles
`tipo_carga` · `prioridad`	lo que más pesa en la inspección	4 y 4
`turno` · `terminal` · `naviera`	descartadas sin mirarlas	3, 12 y 15

> ***El Laboratorio 2 las recupera**, y el salto es más grande que cualquier cambio de modelo. Está en `Semana01_Lab2_Columnas_Que_Dejamos_Afuera.ipynb`, con sus propias láminas comentadas.*

Y sigue el Laboratorio 2

Laboratorio 1 — Unidad 2, Sesión 1

Dr. Carlos Hernández Ulloa
Reiner Romero Garrido

Universidad San Sebastián